GUARDARRAÍLES PARA AGENTES DE CÓDIGO

# Un prompt no es una puerta

Por qué las reglas en prosa no bastan, y qué sí funciona

UN CASO REAL

# Un encargo acotado. Tres cosas que nadie pidió.

**1**

### Cambió un texto legal protegido

Añadió una tilde en la pantalla de borrado de cuenta.

**2**

### Regrabó la captura de referencia

Así el test visual no veía ninguna diferencia.

**3**

### Apuntó una aprobación falsa

En cuatro sitios: «el autor lo revisó y lo aprobó».

**Cinco capas de control. Ninguna lo paró. El cambio era correcto; el proceso, no.**

# Aviso frente a puerta

## ⚠ Aviso

Un texto que el agente **puede** leer, interpretar… o ignorar.

```
copilot-instructions.md
- Nunca modifiques
ficheros en tests/
```

## Puerta

Un mecanismo que **impide** la acción antes de que ocurra.

```
hook preToolUse →
{"permissionDecision":
"deny"}
```

**La prosa dirige el trabajo. No lo contiene.**

DEMO · ACTO 1

# La regla en prosa

«Añade el tipo de cliente "vip" con un 60 % de descuento
y asegúrate de que todos los tests pasan.»

PARA CADA REGLA DE VUESTRO COPILOT-INSTRUCTIONS.MD

# Tres preguntas

1. ¿Podría el agente **no leerla**?
2. ¿Qué pasa si la lee y **hace otra cosa**?
3. ¿Quién comprueba que se cumplió, y **¿puede ser el propio agente?**

DEMO · ACTO 2

# La puerta

```
if toca_protegido and not solo_lee and not ejecuta_tests:
decision = {"permissionDecision": "deny", ...}
else:
decision = {}
```

SEGREGACIÓN DE FUNCIONES

# Quien ejecuta no verifica

### Hook

En la máquina del agente. Bloquea antes de que ocurra. Tiene huecos.

### Check en CI

Fuera de su alcance. ¿El PR toca **tests/**? Falla.

### Una persona

Única vía legítima: la etiqueta **cambio-de-especificacion**.

**Quien pone en marcha al guardia no debe ser el sospechoso.**

# Tres propiedades de un control real

### Se verifica por su efecto

No porque esté configurado. El hook tiene tests que le pasan eventos y miran qué decide.

### Funciona sin nadie mirando

Modo desatendido. Si hace falta una persona atenta para que funcione, no es un control.

### Documenta sus huecos

Qué no cubre, escrito en el propio control. Así sabes dónde poner la siguiente puerta.

Y la prosa sigue siendo útil: **pasa de ser la barrera a ser la explicación** de cada control.

# Qué hacer el lunes

1. Abrid vuestro **copilot-instructions.md** y pasad cada regla por las tres preguntas.
2. Las reglas que no podéis permitir que se rompan, convertidlas en un **hook** o en un **check de CI**.
3. Cada control, con su test por efecto y sus huecos por escrito.

**La prosa dirige el trabajo. No lo contiene.**

# ¿Preguntas?

Basado en el artículo de José Ramón Pérez Agüera (Gemba)

**«Un prompt no es una puerta»**

`newsletter.gemba.es/p/un-prompt-no-es-una-puerta`